



西安交通大学  
XI'AN JIAOTONG UNIVERSITY

概率统计与随机过程

## 第四章：大数定律与中心极限定理

赵俊舟

junzhou.zhao@xjtu.edu.cn

2025 年 4 月 9 日

# 目录

- 1 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理

# 目录

- 1 随机变量序列的收敛性
  - 概率与事件发生频率的稳定值
  - 切比雪夫不等式
  - 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理

# 目录

- 1 随机变量序列的收敛性
  - 概率与事件发生频率的稳定值
  - 切比雪夫不等式
  - 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理

# 抛硬币试验

- **抛硬币试验**：连续抛一枚硬币  $n$  次，记  $A = \{\text{正面朝上}\}$ ， $n_A$  表示  $n$  次试验中事件  $A$  发生的次数，则事件  $A$  发生的频率为


$$f_n(A) = \frac{n_A}{n}$$

- 概率论历史上几个有名的“抛硬币”试验：

实验者	$n$	$n_A$	$n_A/n$
德·摩根	2048	1061	0.5181
蒲丰	4048	2048	0.5069
皮尔逊	12000	6019	0.5016
皮尔逊	24000	12012	0.5005
罗曼诺夫斯基	80640	39699	0.4923


- 可见  $f_n(A) = \frac{n_A}{n} \rightarrow P(A) = 0.5, \quad n \rightarrow \infty$

# 抛硬币试验中的统计规律性



# 蒲丰投针试验

例 (蒲丰投针试验, 1777 年)



记  $A = \{\text{针与平行线相交}\}$ , 求  $P(A)$ 。

- 令针与平行线的夹角为  $\theta$ , 针的中点与离它比较近的平行线的距离为  $x$ , 则  $\theta \sim U(0, \pi), X \sim U(0, d/2)$
- 针与平行线相交的条件为  $X < \frac{l}{2} \sin \theta$

$$P(A) = P(X < \frac{l}{2} \sin \theta) = \int_0^\pi d\theta \int_0^{\frac{l}{2} \sin \theta} \frac{2}{\pi d} dx = \frac{2l}{\pi d}$$

# 蒲丰投针试验

- 记投针总数为  $n$ ，针与平行线相交次数为  $n_A$ ，则


$$\frac{n_A}{n} \rightarrow \frac{2l}{\pi d} \Rightarrow \frac{2nl}{n_A d} \rightarrow \pi$$

- 19-20 世纪几个有名的“投针”试验

试验者	时间	针长 $d$	$n$	$n_A$	$\hat{\pi}$
Buffon	1777	0.5	2212	704	3.142
Wolf	1850	0.8	5000	2532	3.1596
Smith	1855	0.6	3204	1219	3.1554
De.morgan	1860	1	600	383	3.137
Fox	1884	0.75	1030	489	3.1595
Lazzerini	1901	0.83	3408	1801	3.14159
Reina	1925	0.54	2520	859	3.1683



# 蒲丰投针试验中的统计规律性



# 概率与事件发生频率的稳定值



- 在大量重复试验中，事件发生的频率稳定于它发生的概率，即**频率稳定于概率**。
- 频率的稳定性**：设  $n$  次独立重复试验中事件  $A$  发生的次数为  $n_A$ ，则当  $n$  越来越大时，有

$$f_n(A) = \frac{n_A}{n} \rightarrow P(A), \quad n \rightarrow \infty$$

## 问题

- ① 频率稳定于概率，但是“稳定”的严格数学定义是什么？
- ② 如何定义随机变量的收敛性？

# 目录

- 1 随机变量序列的收敛性
  - 概率与事件发生频率的稳定值
  - 切比雪夫不等式
  - 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理

# 切比雪夫不等式

## 定理 (切比雪夫不等式)

设随机变量  $X$  的数学期望  $\mathbb{E}(X)$  和方差  $D(X)$  都存在, 则对任意常数  $\epsilon > 0$ , 有

$$P(|X - \mathbb{E}(X)| \geq \epsilon) \leq \frac{D(X)}{\epsilon^2}$$

或

$$P(|X - \mathbb{E}(X)| < \epsilon) \geq 1 - \frac{D(X)}{\epsilon^2}$$

- 如果随机变量  $X$  的方差  $D(X)$  越小, 则随机变量  $X$  落入区间  $(\mathbb{E}(X) - \epsilon, \mathbb{E}(X) + \epsilon)$  的概率就越大;
- 切比雪夫不等式表明, 方差是反映随机变量取值集中在  $\mathbb{E}(X)$  附近的程度的数量指标。

# 切比雪夫不等式的证明

## 引理 (Markov 不等式)

对随机变量  $X$ , 若  $\mathbb{E}(|X|^r) < \infty, r > 0$ , 则对任意  $\epsilon > 0$ , 有

$$P(|X| \geq \epsilon) \leq \frac{\mathbb{E}(|X|^r)}{\epsilon^r}$$

## 证明.

在 Markov 不等式中, 以  $X - \mathbb{E}(X)$  代替  $X$ , 并令  $r = 2$ , 则对任意正数  $\epsilon$ , 有

$$P(|X - \mathbb{E}(X)| \geq \epsilon) \leq \frac{\mathbb{E}([X - \mathbb{E}(X)]^2)}{\epsilon^2} = \frac{D(X)}{\epsilon^2}$$



# 举例：切比雪夫不等式

## 例 (估计及格率的下界)

若某班考试平均成绩是 75 分，方差为 10，估计及格率下界。

- 设随机变量  $X$  表示学生成绩，则  $\mathbb{E}(X) = 75, D(X) = 10$ 。
- 于是

$$\begin{aligned} P(60 \leq X \leq 100) &= P(-15 \leq X - 75 \leq 25) \\ &\geq P(|X - 75| < 15) \geq 1 - \frac{10}{225} = 0.956 \end{aligned}$$

- 表明及格率至少为 95.6%。
- 若  $X \sim N(75, 10)$ ，则实际概率为

$$P(60 \leq X \leq 100) = P\left(\frac{-15}{\sqrt{10}} \leq \frac{X - 75}{\sqrt{10}} \leq \frac{25}{\sqrt{10}}\right) \approx 1$$

# 切比雪夫不等式

- 切比雪夫不等式所得概率下界可能与实际概率相差较大。
- 切比雪夫不等式经常作为理论工具，用于证明某些定理。

# 目录

- 1 随机变量序列的收敛性
  - 概率与事件发生频率的稳定值
  - 切比雪夫不等式
  - 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理



# 随机变量序列的收敛性

- 目标：研究随机变量序列  $\{X_n: n = 1, 2, \dots\}$  的收敛性。
- 高等数学中，级数  $\{x_n: n = 1, 2, \dots\}$  的收敛性可以定义为：
$$\lim_{n \rightarrow \infty} x_n = x$$
- 能否直接将级数的收敛性推广到随机变量序列的收敛性？

# 随机变量序列的收敛性

## 例

研究随机变量序列  $\{X_n: n = 1, 2, \dots\}$ 。设  $X_n \sim N(0, 1)$ ，能否说  $X_n$  收敛到  $X \sim N(0, 1)$ ，即  $\lim_{n \rightarrow \infty} X_n = X$ ？

**不能!** 因为对于连续型随机变量， $P(X_n = X) = 0, \forall n$ 。

## 例

研究随机变量序列  $\{X_n: n = 1, 2, \dots\}$ 。设  $X_n \sim N(0, 1/n)$ ，当  $n$  很大时， $X_n$  集中到 0，能否说  $X_n$  收敛到 0，即  $\lim_{n \rightarrow \infty} X_n = 0$ ？

**不能!** 因为对于连续型随机变量， $P(X_n = 0) = 0, \forall n$ 。

**💡 需要提出新的数学工具，能够适用于研究随机变量序列的收敛性!**

# 依概率收敛

## 定义 (依概率收敛)

设  $\{X_n: n = 1, 2, \dots\}$  为随机变量序列,  $X$  是另一个随机变量, 如果对任意  $\epsilon > 0$  有

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0$$

或

$$\lim_{n \rightarrow \infty} P(|X_n - X| < \epsilon) = 1$$

则称随机变量序列  $\{X_n\}$  依概率收敛于  $X$ , 记作  $X_n \xrightarrow{P} X$ 。

特别地, 若  $X$  为单点分布, 即  $P(X = a) = 1$ , 则称随机变量序列  $\{X_n\}$  依概率收敛于常数  $a$ , 记作  $X_n \xrightarrow{P} a$ 。

# 依概率收敛

## 定理

如果  $X_n \xrightarrow{p} a, Y_n \xrightarrow{p} b$ , 又函数  $g(x, y)$  在点  $(a, b)$  处连续, 则  $g(X_n, Y_n) \xrightarrow{p} g(a, b)$ 。

特例, 如果  $X_n \xrightarrow{p} a, Y_n \xrightarrow{p} b$ , 则:

$$X_n \pm Y_n \xrightarrow{p} a \pm b$$

$$X_n Y_n \xrightarrow{p} ab$$

$$\frac{X_n}{Y_n} \xrightarrow{p} \frac{a}{b} \quad (Y_n, b \neq 0)$$

# 依分布收敛

## 定义 (依分布收敛)

设  $\{X_n\}$  为随机变量序列, 其分布函数序列为  $\{F_n(x)\}$ 。  $X$  是随机变量, 其分布函数为  $F(x)$ 。 若对  $F(x)$  的每个连续点  $x$ , 有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

则称**随机变量序列  $\{X_n\}$  依分布收敛于  $X$** , 记作  $X_n \xrightarrow{d} X$ , 或称**分布函数序列  $\{F_n(x)\}$  弱收敛于  $F(x)$** , 记作  $F_n(x) \xrightarrow{w} F(x)$ 。

- 依分布收敛是最宽松的收敛方式之一;
- 一个依概率收敛的随机变量序列必然也依分布收敛到同一个极限, 即**依概率收敛强于依分布收敛**;
- 依分布收敛蕴含依概率收敛当且仅当依分布收敛的极限是一个常数。

# 举例：随机变量序列的收敛性

## 例 (随机变量序列的收敛性分析)

设随机变量  $X_n \sim N(0, 1/n)$ ，分析  $\{X_n\}$  的收敛性。

- 对任意  $\epsilon > 0$ ，由切比雪夫不等式，有

$$P(|X_n| \geq \epsilon) \leq \frac{D(X_n)}{\epsilon^2} = \frac{1}{n\epsilon^2} \rightarrow 0$$

- 所以  $X_n \xrightarrow{p} 0$
- 注意到  $\sqrt{n}X_n \sim N(0, 1)$ ，令  $Z \triangleq \sqrt{n}X_n$ ，则  $Z \sim N(0, 1)$ 。

- 当  $t < 0$  时，


$$F_n(t) = P(X_n < t) = P(\sqrt{n}X_n < \sqrt{nt}) = P(Z < \sqrt{nt}) \rightarrow 0$$

- 当  $t > 0$  时，

$$F_n(t) = P(X_n < t) = P(Z < \sqrt{nt}) \rightarrow 1$$

# 举例：随机变量序列的收敛性

- 令  $F(t)$  为单点分布  $P(X = 0) = 1$  的分布函数，则对于任意  $t \neq 0$ ，有  $\lim_{n \rightarrow \infty} F_n(t) = F(t)$ 。



- 说明  $X_n \xrightarrow{d} 0$
- 注意  $F_n(0) = 1/2 \neq F(0) = 1$ ，所以在  $t = 0$  处不收敛，但不影响  $X_n$  的依分布收敛性，因为  $t = 0$  不是  $F$  的连续点。

# 举例：随机变量序列的收敛性

## 例（依概率收敛性与期望）

设随机变量  $X_n$  的分布律为

$x$	0	$n^2$
$p$	$1 - 1/n$	$1/n$

分析  $\{X_n\}$  的依概率收敛性及  $X_n$  的数学期望的极限。

- 因为对任意  $\epsilon > 0$ , 有

$$P(|X_n| < \epsilon) = P(X_n = 0) = 1 - \frac{1}{n} \rightarrow 1$$

- 所以  $X_n \xrightarrow{p} 0$ 。

- 但是  $\mathbb{E}(X_n) = n^2 \times 1/n = n \neq 0$ , 且  $\lim_{n \rightarrow \infty} \mathbb{E}(X_n) = \infty$ 。



# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

- 伯努利大数定律
- 切比雪夫大数定律
- 辛钦大数定律

## 3 中心极限定理

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

- 伯努利大数定律
- 切比雪夫大数定律
- 辛钦大数定律

## 3 中心极限定理

# 伯努利大数定律

## 定理 (伯努利大数定律)

设  $\eta_n \sim B(n, p)$ , 则对任意常数  $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{\eta_n}{n} - p \right| < \epsilon \right) = 1$$

## 证明.

因为  $\mathbb{E}(\eta_n) = np$ ,  $D(\eta_n) = np(1-p)$ , 由切比雪夫不等式, 对任意  $\epsilon > 0$ , 有

$$P \left( \left| \frac{\eta_n}{n} - p \right| < \epsilon \right) = P(|\eta_n - np| < n\epsilon) \geq 1 - \frac{np(1-p)}{(n\epsilon)^2} = 1 - \frac{p(1-p)}{n\epsilon^2}$$

令  $n \rightarrow \infty$ , 得

$$1 \geq \lim_{n \rightarrow \infty} P \left( \left| \frac{\eta_n}{n} - p \right| < \epsilon \right) \geq \lim_{n \rightarrow \infty} \left( 1 - \frac{p(1-p)}{n\epsilon^2} \right) = 1$$

# 伯努利大数定律

- 伯努利大数定律是概率论历史上最早出现的大数定律，由瑞士数学家雅各布·伯努利在著作《猜度术》中首次提出。
- 伯努利大数定律描述了当试验次数  $n \rightarrow \infty$  时，频率  $\eta_n/n$  的极限状态：事件发生的频率  $\eta_n/n$  依概率收敛于概率  $p$ ，即  $\frac{\eta_n}{n} \xrightarrow{p} p$ ，或者说频率依概率收敛于概率。
- 伯努利大数定律提供了用频率来确定概率的理论依据。
- 伯努利大数定律也是蒙特卡洛（Monte Carlo）方法的数学理论基础。


# 举例：伯努利大数定律

例 (蒙特卡洛方法计算定积分，也称为随机投点法)

设  $f(x) \in [0, 1]$ ，求  $f(x)$  在区间  $[0, 1]$  上的积分值  $\int_0^1 f(x) dx$ 。

- 设  $(X, Y)$  服从正方形区域  $[0, 1] \times [0, 1]$  上的均匀分布，即  $X \sim U(0, 1), Y \sim U(0, 1)$
- 记事件  $A = \{Y \leq f(X)\}$ ，则事件  $A$  发生的概率为

$$p = P(Y \leq f(X)) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx \triangleq J$$



- 即定积分的值  $J$  就是事件  $A$  发生的概率。
- 由伯努利大数定律，可以用重复试验中事件  $A$  发生的频率作为  $p$  的估计值。

# 举例：伯努利大数定律

## 随机投点法

- ① 用计算机产生  $[0, 1]$  上的均匀分布的  $2n$  个随机数： $x_i, y_i$ ,  $i = 1, \dots, n$ , 例如  $n = 10^5$ 。
- ② 对  $n$  对数据  $(x_i, y_i), i = 1, \dots, n$ , 记录满足  $y_i \leq f(x_i)$  的次数, 这就是事件  $A$  发生的频数  $\eta_n$ , 则事件  $A$  发生的频率  $\eta_n/n \approx J$ 。

例如计算  $\frac{1}{\sqrt{2\pi}} \int_0^1 e^{-x^2/2} dx$ , 其精确值和  $n = 10^4, n = 10^5$  时的近似值如下

精确值	$n = 10^4$	$n = 10^5$
0.341344	0.340698	0.341355

# 举例：伯努利大数定律

- 对于一般区间  $[a, b]$  上的定积分  $J' = \int_a^b g(x) dx$ ，可以通过线性变换  $y = (x - a)/(b - a)$  转化成  $[0, 1]$  区间上的积分。

- 进一步，若  $c \leq g(x) \leq d$ ，可令

$$f(y) \triangleq \frac{g(a + (b - a)y) - c}{d - c}$$

则  $0 \leq f(y) \leq 1$ 。

- 此时有

$$J' = \int_a^b g(x) dx = S_0 \int_0^1 f(y) dy + c(b - a)$$

其中  $S_0 = (b - a)(d - c)$ 。

- 说明用蒙特卡罗方法计算定积分具有普遍意义。

# 大数定律的一般形式

- 伯努利大数定律讨论的是一个独立同分布随机变量序列  $\{X_n\}$ ，每个随机变量  $X_i$  都服从两点分布，即  $X_i \sim B(1, p)$ 。
- 考察该序列前  $n$  个随机变量之和  $\eta_n = \sum_{i=1}^n X_i$ ，其频率和频率的数学期望分别为

$$\frac{\eta_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i \quad \mathbb{E} \left( \frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = p$$

- 那么伯努利大数定律可表述为：对任意  $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \right| < \epsilon \right) = 1$$

- 上式为大数定律的一般表达形式，不同大数定律的区别只是针对不同的随机变量序列。



# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

- 伯努利大数定律
- 切比雪夫大数定律
- 辛钦大数定律

## 3 中心极限定理

# 切比雪夫大数定律

## 定理 (切比雪夫大数定律)

设  $\{X_n\}$  是两两不相关的随机变量序列, 若每个  $X_i$  的方差存在, 且有共同上界, 即  $D(X_i) \leq c, i = 1, \dots, n$ , 则对任意  $\epsilon > 0$ , 都有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \right| \geq \epsilon \right) = 0$$

或

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \right| < \epsilon \right) = 1$$

**注意:** 切比雪夫大数定律只要求  $\{X_n\}$  两两不相关, 并不要求它们独立同分布。

# 切比雪夫大数定律

## 证明.

- 令  $Y_n = \frac{1}{n} \sum_{i=1}^n X_i$ , 则  $\mathbb{E}(Y_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i)$ 。
- 由于  $\{X_n\}$  两两不相关, 则有

$$D(Y_n) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) \leq \frac{c}{n}$$

- 对任意  $\epsilon > 0$ , 应用切比雪夫不等式

$$1 \geq P(|Y_n - \mathbb{E}(Y_n)| < \epsilon) \geq 1 - \frac{D(Y_n)}{\epsilon^2} \geq 1 - \frac{c}{n\epsilon^2}$$

- 令  $n \rightarrow \infty$ , 由夹逼法则得

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i)\right| < \epsilon\right) = 1$$

# 切比雪夫大数定律

## 推论

设  $\{X_n\}$  是相互独立的随机变量序列，且每个  $X_i$  有相同的期望  $\mathbb{E}(X_i) = \mu$  和方差  $D(X_i) = \sigma^2$ ，则对任意  $\epsilon > 0$ ，都有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \epsilon \right) = 1$$

- 当  $n$  很大时，事件  $\left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \epsilon$  发生的概率接近 1。
- 称概率接近于 1 的事件为**大概率事件**，称概率接近于 0 的事件为**小概率事件**。
- 实践发现，大概率事件在一次试验中几乎肯定是要发生，而小概率事件在一次试验中几乎不可能发生，称为**实际推断原理**。

# 实际推断原理与数学期望的统计估计

- 设  $X$  是一个概率分布未知的随机变量，希望估计其数学期望  $\mathbb{E}(X)$ 。
- 对  $X$  进行一次  $n$  重观测试验，记  $X_i$  为第  $i$  次观测的结果， $i = 1, \dots, n$ ， $X_i$  为随机变量且彼此相互独立。
- 当  $n$  很大时， $\left| \frac{1}{n} \sum_{i=1}^n X_i - \mathbb{E}(X) \right| < \epsilon$  为大概率事件。
- 因此对一次  $n$  重观测试验的结果  $x_1, \dots, x_n$ ，几乎可以肯定有  $\left| \frac{1}{n} \sum_{i=1}^n x_i - \mathbb{E}(X) \right| < \epsilon$ ，所以  $\mathbb{E}(X) \approx \frac{1}{n} \sum_{i=1}^n x_i$ 。
- 以上方法称为**数学期望的统计估计法**。

# 弱大数定律

上述推论的一个特殊情况是随机变量序列独立同分布。

**定理 (弱大数定律 The Weak Law of Large Numbers, WLLN)**

设  $\{X_n\}$  是独立同分布的随机变量序列, 且存在数学期望  $\mathbb{E}(X_i) = \mu$  与方差  $D(X_i) = \sigma^2, i = 1, 2, \dots$ , 则对任意  $\epsilon > 0$  有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \epsilon \right) = 0$$

或

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \epsilon \right) = 1$$

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

- 伯努利大数定律
- 切比雪夫大数定律
- 辛钦大数定律

## 3 中心极限定理

# 辛钦大数定律

- 注意：以上大数定律都要求方差存在（方差存在则数学期望必然存在，但反之不一定成立）。
- 辛钦大数定律去掉了方差存在的假设，仅要求数学期望存在。

## 定理（辛钦大数定律）

设  $\{X_n\}$  是独立同分布的随机变量序列，若每个随机变量  $X_i$  的数学期望  $\mathbb{E}(X_i) = \mu$  存在，则对任意  $\epsilon > 0$  有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \epsilon \right) = 0$$

或

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \epsilon \right) = 1$$



# 举例：辛钦大数定律

例

设  $\{X_n\}$  是独立同分布的随机变量序列，其分布律为

$$P(X_k = (-1)^{k-1}k) = \frac{6}{\pi^2 k^2} \quad k = 1, 2, \dots$$

问  $\{X_n\}$  是否依概率收敛于其数学期望？

由于级数

$$\sum_{k=1}^{\infty} |(-1)^{k-1}k| \frac{6}{\pi^2 k^2} = \frac{6}{\pi^2} \sum_{k=1}^{\infty} \frac{1}{k}$$

不绝对收敛，故  $X_k$  的数学期望不存在，从而  $\{X_n\}$  不依概率收敛于期望。

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

## 3 中心极限定理

- 随机变量和的极限
- 中心极限定理
- 应用举例

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

## 3 中心极限定理

- 随机变量和的极限
- 中心极限定理
- 应用举例

# 随机变量和的极限


- 大数定律讨论的是多个随机变量的平均  $\frac{1}{n} \sum_{i=1}^n X_i$  的渐进性质，那么独立随机变量和  $\sum_{i=1}^n X_i$  又有怎样的性质？
- 例如，机床加工工件时总有误差，导致误差的随机因素包括：
  - 机床振动与转速、刀具装配与磨损、钢材成分与产地、
  - 操作者注意力集中程度、当天的情绪、
  - 量具误差、测量技术、环境温度、湿度、照明、电压等。
- 误差由大量微小的相互独立的随机因素叠加而成，每个因素的出现无法控制、随机、时有时无、时大时小、时正时负。
- 记误差为  $Y_n$ ，那么  $Y_n$  是很多微小随机波动  $X_1, \dots, X_n$  之和
 
$$Y_n = X_1 + X_2 + \dots + X_n,$$

人们关心当  $n \rightarrow \infty$  时， $Y_n$  的分布是怎样的？

# 均匀分布和的极限

## 例 (独立同均匀分布随机变量和的极限)

设  $\{X_n\}$  为独立同分布随机变量序列, 且  $X_i \sim U(0, 1)$ 。记  $Y_n = \sum_{i=1}^n X_i$ , 利用卷积公式可以求出  $Y_n$  的概率密度  $f_n(y)$ 。




💡 随着  $n$  的增大,  $f_n(y)$  愈来愈平滑, 愈来愈接近正态分布的概率密度曲线。同时, 曲线也在右移, 方差变大。


# 其他分布和的极限

- 当  $X_i$  服从其他分布时,  $Y_n = \sum_{i=1}^n X_i$  的分布也观察到类似的现象。

$$X_i \sim B(1, 0.6)$$



$$X_i \sim P(1)$$



💡 随着  $n$  的增大,  $f_n(y)$  愈来愈接近正态分布的概率密度曲线的同时, 曲线也在右移, 方差变大。

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

## 3 中心极限定理

- 随机变量和的极限
- 中心极限定理
- 应用举例

# 独立同分布随机变量和的正态近似

- 为避免当  $n \rightarrow \infty$  时  $Y_n$  的均值和方差趋于无穷大, 对  $Y_n$  进行**标准化**:  $Y_n^* \triangleq \frac{Y_n - \mathbb{E}(Y_n)}{\sqrt{D(Y_n)}}$ , 使  $\mathbb{E}(Y_n^*) = 0, D(Y_n^*) = 1$ 。

## 定理 (林德贝格-勒维中心极限定理)

设  $\{X_n\}$  是独立同分布的随机变量序列, 且  $\mathbb{E}(X_n) = \mu$ ,  $D(X_n) = \sigma^2 > 0$ , 则对任意  $y \in \mathbb{R}$ , 有

$$\lim_{n \rightarrow +\infty} P(Y_n^* \leq y) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt$$

- 无论随机变量序列  $\{X_n\}$  服从什么分布, 只要独立同分布且存在期望和方差, 则  $Y_n^*$  **依分布收敛于** 标准正态分布  $N(0, 1)$ 。



# 举例：独立同分布随机变量和的正态近似

## 例 (元件寿命)

根据以往经验，某种电器元件的寿命服从均值为 100 小时的指数分布。现随机抽取 36 只，设它们的寿命是独立同分布的，求这 36 只元件的寿命总和超过 4000 小时的概率。

- 设  $X_i$  表示第  $i$  只元件的寿命， $i = 1, \dots, 36$ ，则  $\mathbb{E}(X_i) = 100$ ， $D(X_i) = 100^2$ 。

- 这 36 只元件的总寿命为  $\sum_{i=1}^{36} X_i$ ，所求概率为

$$P\left(\sum_{i=1}^{36} X_i > 4000\right) = P\left(\frac{\sum_{i=1}^{36} X_i - 3600}{\sqrt{36} \times 100} > \frac{4000 - 3600}{600}\right)$$

$$\approx 1 - \Phi\left(\frac{2}{3}\right) = 0.2514$$

# 举例：独立同分布随机变量和的正态近似

## 例 (测量误差)

多次测量一个物理量，每次都产生一个随机误差且服从  $U(-0.5, 0.5)$ 。问：(1) 100 次测量的算术平均值与真实值的绝对值小于 0.05 的概率是多少？(2) 需要进行多少次测量才能使测量的算术均值与其真值的差小于 0.05 的概率不小于 0.95？

- 设  $a$  为真值， $X_i$  表示第  $i$  次测量值， $\epsilon_i$  表示第  $i$  次测量误差。
- 所以  $X_i = a + \epsilon_i$ ， $\epsilon_i \sim U(-0.5, 0.5)$ ， $\mathbb{E}(\epsilon_i) = 0$ ， $D(\epsilon_i) = 1/12$ 。

$$\begin{aligned} P\left(\left|\frac{1}{100} \sum_{i=1}^{100} X_i - a\right| < 0.05\right) &= P\left(\left|\sum_{i=1}^{100} X_i - 100a\right| < 5\right) \\ &= P\left(\left|\sum_{i=1}^{100} \epsilon_i\right| < 5\right) = P\left(\left|\frac{\sum_{i=1}^{100} \epsilon_i}{\sqrt{100/12}}\right| < \frac{5\sqrt{12}}{10}\right) = P(|Z| < \sqrt{3}) \end{aligned}$$

# 举例：独立同分布随机变量和的正态近似

$$= \Phi(\sqrt{3}) - \Phi(-\sqrt{3}) = 2\Phi(\sqrt{3}) - 1 = 0.9164$$

- 设需要测量  $n$  次，测量的算术均值与真值差小于 0.05 的概率为

$$\begin{aligned} P\left(\frac{1}{n} \sum_{i=1}^n X_i - a < 0.05\right) &= P\left(\sum_{i=1}^n X_i - na < 0.05n\right) \\ &= P\left(\frac{\sum_{i=1}^n \epsilon_i}{\sqrt{n/12}} < \frac{0.05n}{\sqrt{n/12}}\right) \\ &\approx \Phi(0.1\sqrt{3}n) \end{aligned}$$

- 令  $\Phi(0.1\sqrt{3}n) \geq 0.95$ ，得  $n \geq 90.75$

# 二项分布的正态近似

## 定理 (德莫弗-拉普拉斯极限定理)

设  $n$  重伯努利试验中, 事件  $A$  在每次试验中出现的概率为  $p \in (0, 1)$ 。记  $\eta_n$  为  $n$  次试验中事件  $A$  出现的次数, 且记

$$Y_n^* = \frac{\eta_n - np}{\sqrt{np(1-p)}}$$

则对任意实数  $y$ , 有

$$\lim_{n \rightarrow +\infty} P(Y_n^* \leq y) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt$$

- 二项分布的极限分布是正态分布, 故也称为“二项分布的正态近似”。当  $n$  较大时,  $\eta_n$  可用  $N(np, np(1-p))$  来近似。
- 泊松定理同时给出了二项分布的泊松近似。一般  $p$  较小  $np$  适中时, 泊松近似较好; 在  $np > 5$  时, 正态近似较好。

# 举例：二项分布的正态近似

## 例 (性状遗传)

根据孟德尔遗传理论，红、黄两种番茄杂交的第二代结红果植株和黄果植株的比率为 3 : 1，现在种植番茄杂交种 400 株，试求黄果植株介于 83 ~ 117 的概率。

- 令  $X$  表示结黄果的植株数，由于结红、黄果彼此独立，则  $X \sim B(400, 0.25)$ ，且  $\mathbb{E}(X) = 100$ ， $D(X) = 75$ 。
- 由德莫弗-拉普拉斯定理得

$$\begin{aligned} P(83 < X < 117) &= P\left(\frac{83 - 100}{\sqrt{75}} < \frac{X - 100}{\sqrt{75}} < \frac{117 - 100}{\sqrt{75}}\right) \\ &\approx \Phi(1.96) - \Phi(-1.96) \\ &= 2\Phi(1.96) - 1 \\ &= 0.95 \end{aligned}$$

# 目录

## 1 随机变量序列的收敛性

## 2 大数定律

## 3 中心极限定理

- 随机变量和的极限
- 中心极限定理
- 应用举例

# 中心极限定理的应用

## 例 (治愈率)

某药厂断言, 该厂生产的某种药品对于医治一种疾病的治愈率为 0.8。医院任意抽查服用该药的 100 位病人, 若其中多于 75 人治愈, 就接收断言, 否则拒绝断言。

- (1) 若实际上该药治愈率为 0.8, 接受该断言的概率是多少?
- (2) 若实际上该药治愈率为 0.7, 接受该断言的概率是多少?

用  $X$  表示 100 人中的治愈人数。

- (1)  $X \sim B(100, 0.8)$ , 则

$$\begin{aligned} P(X > 75) &= P\left(\frac{X - 100 \times 0.8}{\sqrt{100 \times 0.8 \times 0.2}} > \frac{75 - 80}{4}\right) \\ &\approx 1 - \Phi(-1.25) \\ &= \Phi(1.25) = 0.8944 \end{aligned}$$

# 中心极限定理的应用

(2)  $X \sim B(100, 0.7)$ , 则

$$\begin{aligned} P(X > 75) &= P\left(\frac{X - 100 \times 0.7}{\sqrt{100 \times 0.7 \times 0.3}} > \frac{75 - 70}{\sqrt{21}}\right) \\ &\approx 1 - \Phi(1.09) \\ &= 0.1379 \end{aligned}$$



# 中心极限定理的应用

## 例 (保单售价)

某保险公司欲推出一项新业务，经分析，该业务每份保单的年赔付金额  $X \sim \exp(0.001)$ 。试建立每份保单的售价  $Q$  与参保人数  $n$  的关系，使得保险公司有 95% 的概率盈利。

用  $X_i$  表示第  $i$  个人的赔付金， $i = 1, \dots, n$ ，则  $\{X_i\}$  独立同分布。 $\mathbb{E}(X_i) = 1000$ ,  $D(X_i) = 1000^2$ 。盈利等价于  $\sum_{i=1}^n X_i \leq nQ$ 。

$$\begin{aligned} P\left(\sum_{i=1}^n X_i \leq nQ\right) &= P\left(\frac{\sum_{i=1}^n X_i - 1000n}{1000\sqrt{n}} \leq \frac{n(Q - 1000)}{1000\sqrt{n}}\right) \\ &\approx \Phi\left(\frac{n(Q - 1000)}{1000\sqrt{n}}\right) = \Phi\left(\left(\frac{Q}{1000} - 1\right)\sqrt{n}\right) \\ &= 0.95 \end{aligned}$$

# 中心极限定理的应用

查表得  $(\frac{Q}{1000} - 1)\sqrt{n} = 1.65$ , 所以

$$Q = 1000 + \frac{1650}{\sqrt{n}}$$

# 中心极限定理的应用

## 例 (次品率)

某种产品的次品率为 5%，装箱时，

(1) 若每箱装 100 只，问至少有两件次品的概率？

(2) 若要以 99% 的把握保证每箱合格品不少于 100 只，问每箱至少应多装几只？

(1) 用  $X$  表示每箱次品数，则  $X \sim B(100, 0.05)$ ，于是

$$\begin{aligned} P(X \geq 2) &= P\left(\frac{X - 100 \times 0.05}{\sqrt{100 \times 0.05 \times 0.95}} \geq \frac{2 - 5}{\sqrt{4.75}}\right) \\ &\approx 1 - \Phi(-1.3764) \\ &= \Phi(1.3764) \\ &= 0.9162 \end{aligned}$$

# 中心极限定理的应用

(2) 设每箱应多装  $k$  只, 则  $X \sim B(100 + k, 0.05)$ , 希望  $P(X \leq k) \geq 0.99$ , 于是

$$\begin{aligned}
 & P(X \leq k) \\
 &= P\left(\frac{X - (100 + k) \times 0.05}{\sqrt{(100 + k) \times 0.05 \times 0.95}} \leq \frac{k - (100 + k) \times 0.05}{\sqrt{(100 + k) \times 0.05 \times 0.95}}\right) \\
 &\approx \Phi\left(\frac{k - (100 + k) \times 0.05}{\sqrt{(100 + k) \times 0.05 \times 0.95}}\right) \\
 &\geq 0.99 \\
 &\text{得 } k \geq 11.
 \end{aligned}$$

# 中心极限定理的应用

## 例 (电话交换机)

某单位电话交换机接有 500 部电话，在所有通话中有 96% 次通话是在各分机内进行的。假定每部分机是否需要打外线是相互独立的，问需要配备多少条外线才能以 95% 的概率保证每个分机要用外线时不必等候？

记  $\eta$  表示 500 台分机中同时打外线电话的分机台数，则  $\eta \sim B(500, 0.04)$ 。设需要外线  $k$  条使得  $P(\eta \leq k) \geq 0.95$ ，即

$$\begin{aligned} P(\eta \leq k) &= P\left(\frac{\eta - 500 \times 0.04}{\sqrt{500 \times 0.04 \times 0.96}} \leq \frac{k - 500 \times 0.04}{\sqrt{500 \times 0.04 \times 0.96}}\right) \\ &\approx \Phi\left(\frac{k - 500 \times 0.04}{\sqrt{500 \times 0.04 \times 0.96}}\right) \geq 0.95 \end{aligned}$$

解得  $k \geq 27.23$ ，故需要 28 条。

# 小结

- 1 随机变量序列的收敛性
- 2 大数定律
- 3 中心极限定理